¿QUÉ ES GSF?

Un módulo liviano para detección de acciones en video: **transforma un clasificador de imágenes en un detector de acciones.**

Sudhakaran, Escalera y Lanz, «Gate-Shift-Fuse for Video Action Recognition», TPAMI 2023

Video → Red 2D, frame por frame → **+ GSF: mezcla frames vecinos** → Promedio → Acción

Aprende el tiempo

Decide qué información pasa entre frames vecinos y cuánta conviene mezclar, antes del promedio final.

¿PARA QUÉ SIRVE?

Para reconocer acciones que dependen del **orden** de los frames, sin pagar el costo de entrenar una red 3D desde cero.

Mismos frames, distinto orden.

«abrir»



«cerrar»



Una red 2D que **promedia** lo que ve en cada frame suelto obtiene lo mismo en los dos casos: no los distingue.

Solo red 2D (TSN)
promedia frames sueltos

17,25 %

TSN + GSF
+31,2 puntos

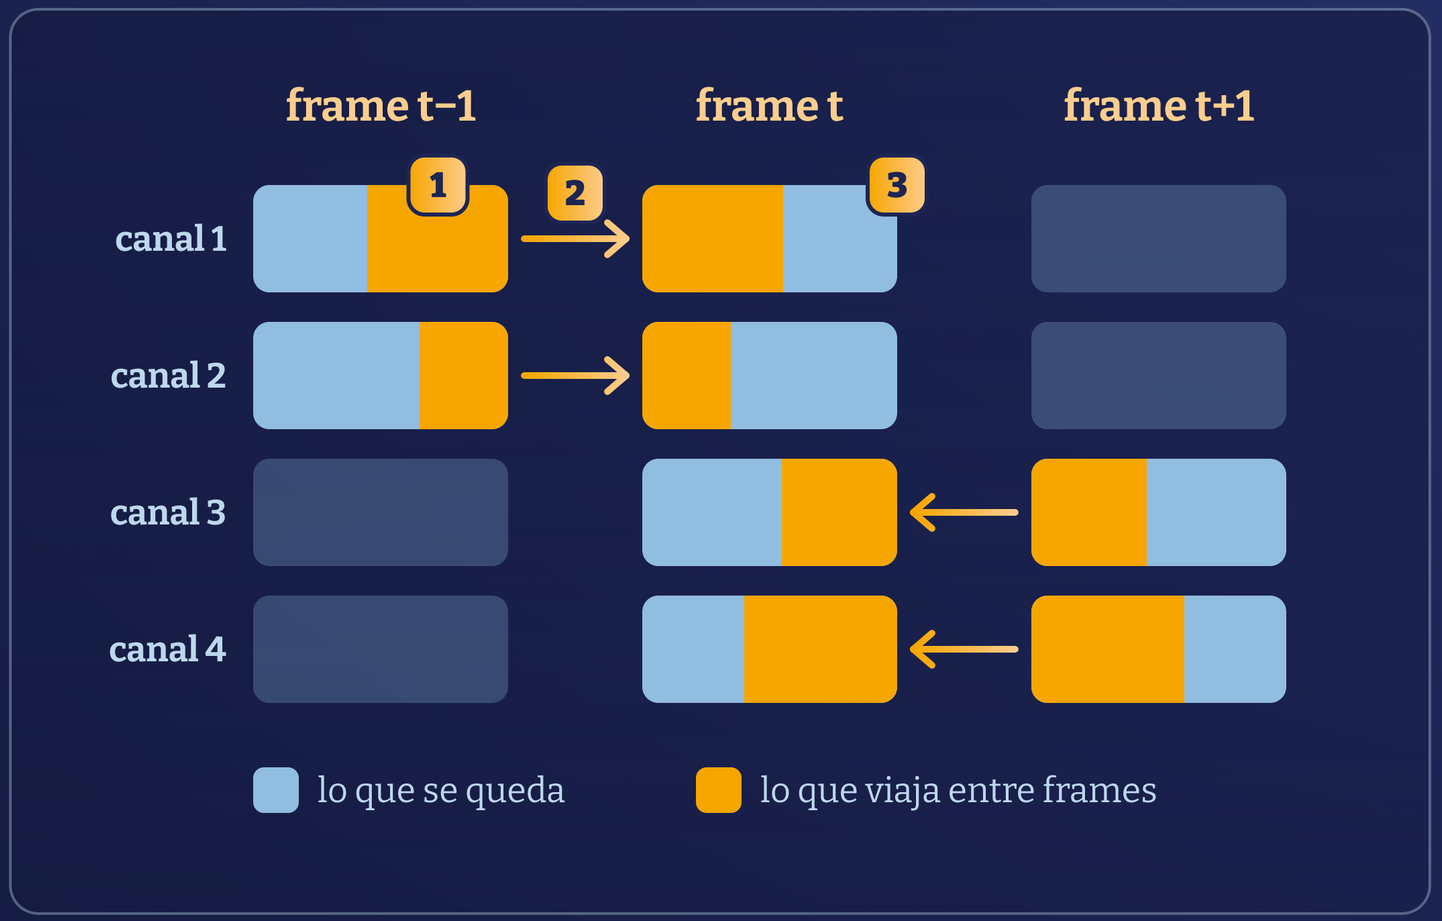
48,44 %

+0,48 %
de parámetros

+0,58 %
de FLOPs

¿CÓMO FUNCIONA?

Cada fila es un canal (una de las características que la red calcula en cada frame) y cada columna, un frame. Miramos qué le llega al frame t.



1 GATE · decide qué viaja

Una conv 3D elige, en cada canal, qué parte viaja (ámbar) y qué parte se queda (celeste).

2 SHIFT · mueve entre frames

Lo que viaja se corre un frame: en los canales 1 y 2 llega desde t−1; en los 3 y 4, desde t+1.

3 FUSE · mezcla

En t se combina lo que llegó con lo que se quedó; un peso aprendido decide cuánto de cada uno.